作业 1

第一部分 编程作业

引言

我们已经学习了用于分类任务的模型。本次编程作业将重点放在分类模型的实现上——朴素贝叶斯（Naïve Bayes）、逻辑回归（Logistic Regression）以及决策树分类（Decision Tree Classification）。为了评估这些方法的有效性，你将使用真实数据集对代码进行训练和测试。我们在此为你提供了一些方法，用于读取训练和测试数据集，并为你存储相关信息。

数据集（Datasets）

所提供的数据集均来自 UCI 机器学习库（UCI Machine Learning Repository）中的分类数据集。你可以使用 data 文件夹中提供的所有数据集，或者通过本文档中给出的链接直接访问数据集。我选择了三个我认为能产生多样化结果的数据集。

国会投票记录数据集（Congressional Voting Records Dataset）

该数据集
(http://archive.ics.uci.edu/ml/datasets/Congressional+Voting+Records)
根据国会议员的投票记录，将其分类为民主党或共和党成员。这是一个相对容易解决的问题，即使使用简单的分类方法（例如朴素贝叶斯分类）也应能获得较高的准确率。该数据集非常适合用于调试目的。

MONKS 问题数据集（MONKS Problems Dataset）

该数据集
(https://archive.ics.uci.edu/dataset/70/monk+s+problems)
具有任意属性，并使用 0 和 1 作为标签。该数据集是为了构造一个难以解决的问题而生成的，并曾用于学习算法竞赛。该数据集中包含三个问题，请务必在所有三个问题上测试你的算法！由于其本身的复杂性，我并不期望你在该数据集上取得很高的性能。请注意，某些属性的取值范围与其他属性不同。

鸢尾花数据集（Iris Dataset）

该数据集
(http://archive.ics.uci.edu/dataset/53/iris)
根据不同特征的尺寸，将花朵划分为不同的鸢尾花类别。这是一个经典的分类问题，因为它同时包含线性可分和线性不可分的类别。

入门（Getting Started）

一个好的第一步是检查所提供的代码框架，并开始使用
numpy（http://www.numpy.org）。创建一个节点（node）类，并思考该方法需要存储哪些数据。如果你在使用 Python 编写数据结构方面经验不足，或者需要帮助理解这些方法的工作原理，请查看压缩包中的文件（classifier.py），并参考网站上的相关资源。

提交要求

请提交你的编程作业，内容应包含以下部分：

- README 文件，包含对每个类的简要说明。如果在提交时存在已知的 bug，请务必注明，并说明你为调试所采取的步骤，以便我们尽可能给予部分分数（如果存在重大 bug 且未加说明，将导致该方法失分）。
- 所有用于调用我们所提供代码框架中的函数、并在所提供数据集上训练和测试你方法的代码。你可以修改我提供的代码，但在这种情况下，请务必一并提交。
- 一份 PDF 或其他文本文件（优先使用 PDF），报告你在每个数据集上的性能分析。你应至少提供三（3）种性能度量指标。

第二部分 书面作业

P1. 朴素贝叶斯分类器（理论）（Naïve Bayes Classifiers (Theory)）

在朴素贝叶斯中，我们假设某一类别的某个特定特征的存在与其他任何特征的存在无关。例如，如果一种水果是绿色、圆形且重量超过 10 磅，它可能被认为是西瓜。在朴素贝叶斯中，我们会将这三个特征视为彼此独立。

设我们的特征 $x_i, i \in [1, d]$是二值的，且具有 d 维，即 $x_i \in \{0,1\}$，输入特征向量为 $x = [x_1, x_2, \cdots, x_d]^T$。对于每个训练样本，目标值 $y \in \{0, 1\}$ 也是一个二值变量。那么我们的模型由参数 $\phi_{i|y=0} = p(x_i = 1|y = 0)$，$\phi_{i|y=1} = p(x_i = 1|y = 1)$，和 $\phi_y = p(y=1)$来参数化，且：

$$p(y) = (\phi_y)^y (1-\phi_y)^{1-y}$$

$$p(x|y=0) = \prod_{i=1}^{d} p(x_i \vee y=0) = \prod_{i=1}^{d} (\phi ¿¿ i \vee y=0)^{x_i} (1-\phi ¿¿ i \vee y=0)^{1-x_i} ¿¿$$

$$p(x|y=1) = \prod_{i=1}^{d} p(x_i \vee y=1) = \prod_{i=1}^{d} (\phi ¿¿ i \vee y=1)^{x_i} (1-\phi ¿¿ i \vee y=1)^{1-x_i} ¿¿$$

a) 写出联合对数似然函数$l(\theta) = \log \prod_{n=1}^{N} p(x^{(n)}, y^{(n)}; \theta)$，其中需用到上述模型参数。$x^{(n)}$ 表示第 n 个数据点，θ 表示所有参数，即 $\{\phi_y, \phi_{i \vee y=0}, \phi_{i \vee y=1}, i = 1,2,\cdots d\}$

b) 利用最大似然估计参数，即求解参数 $\phi_y, \phi_{i \vee y=0}$, and $\phi_{i \vee y=1}$的解。

c) 当新样本点 x 到来时，我们基于模型生成的最可能类别估计进行预测。证明朴素贝叶斯返回的假设是线性的，即若$p(y=0|x)$和 $p(y=1|x)$是模型返回的类别概率，证明存在某

些 α 使得：$p(y=1|x) \geq p(y=0|x)$当且仅当$\alpha^T \tilde{x} \geq 0$ 其中 $\alpha ¿ [\alpha_0, \alpha_1, \alpha_2, \cdots, \alpha_d]^T$，且 $\tilde{x} ¿ [1, x_1, x_2, \cdots, x_d]^T$。

P2. 具有离散特征的朴素贝叶斯（Naive Bayes with discrete features）

考虑如下关于肺部疾病的数据集。你的目标是构建一个朴素贝叶斯分类器，根据病人的症状预测其是否患有支气管炎（Bronchitis）或肺结核（Tuberculosis）。

疾病	X 光阴影	呼吸困难（Dyspnea）	肺部炎症
Bronchitis	Yes	Yes	Yes
Bronchitis	Yes	Yes	Yes
Bronchitis	No	No	Yes
Tuberculosis	No	No	Yes
Tuberculosis	Yes	Yes	No
Tuberculosis	Yes	No	No

1. 列出如果使用极大似然估计（MLE）从该数据中估计朴素贝叶斯模型时，将学习到的所有分布（例如 $P(\text{Dyspnea} \vee \text{Bronchitis})$）。请给出每个分布中所有估计的概率，并展示你的计算过程。

2. 基于你学习到的朴素贝叶斯模型，对具有如下症状的病人进行诊断。请展示你的计算过程。

X 光阴影	呼吸困难	肺部炎症
Yes	No	Yes

P3. k 近邻算法（k-Nearest Neighbor, k-NN）（可选，不计分）

在本题中，你将通过一个小型数据集来更好地理解 k-NN 的一些性质。假设在一个二维平面上存在两类点，以下是所有点的坐标。

红色类别（Red）的点：
(0, 1)、(2, 3)、(4, 4)

蓝色类别（Blue）的点：
(2, 0)、(5, 2)、(6, 3)

a) 绘制 $k=1$ 时的 k 最近邻决策边界。请记住，决策边界被定义为测试点分类发生变化的那条线。使用标准欧几里得距离来确定最近邻。请先将这些点绘制为二维图像，并使用对应的颜色表示不同类别的点（例如蓝色和红色）。

b) 如果将每个点的 y 坐标都乘以 5，$k=1$ 的决策边界将发生什么变化（再画一张图）？请用不超过两句话解释这种效应在处理真实数据时可能带来的问题。

P4. 决策树（Decision Tree）（可选，不计分）

下表包含了一些用于预测病人是否可能发生心脏病发作的样本。

病人 ID	是否胸痛	性别	是否吸烟	是否运动	心脏病发作
1	Yes	Male	No	Yes	Yes
2	Yes	Male	Yes	No	Yes
3	No	Female	Yes	No	Yes
4	No	Male	No	Yes	No
5	Yes	Female	Yes	Yes	Yes
6	No	Male	Yes	Yes	No

a) 使用信息论（Information Theory）中的熵（Entropy）来构建一个预测病人是否可能发生心脏病发作的决策树。请展示计算的每一步。

b) 将该决策树转化为一组决策规则（使用 if-else 语句）。